INSTITUTO SUPERIOR POLITÉCNICO

CURSO DE ENGENHARIA INFORMÁTICA

UNIVERSIDADE KIMPA VITA

Sistema de Predição de Preços de Imóveis

Aplicação de Regressão Linear Múltipla ao Mercado Imobiliário Angolano

PredicaoCasas — Versão 1.0

Linguagem: Java 21 | Interface: Swing | Algoritmo: OLS

Integrantes do Grupo

Boas José Ginga

Faustino Benedito Domingos

João Fernando da Costa

.

Grupo n: 18

Classe: III ano

Período: Tarde

1. Resumo

O presente relatório descreve o desenvolvimento e a arquitectura do sistema PredicaoCasas, uma aplicação desktop desenvolvida em Java que implementa Regressão Linear Múltipla (RLM) pelo método dos Mínimos Quadrados Ordinários (OLS — Ordinary Least Squares) para a estimação do valor de mercado de imóveis residenciais em Luanda, Angola. O sistema integra cinco variáveis preditoras — área construída, número de quartos, número de banheiros, idade do imóvel e distância ao centro urbano — e disponibiliza uma interface gráfica interactiva para visualização de resultados, gestão do dataset e previsão em tempo real. A implementação foi desenvolvida sem recurso a bibliotecas externas de aprendizagem automática, demonstrando a viabilidade de construir modelos de regressão a partir de primeiros princípios matemáticos.

2. Introdução

A avaliação precisa do valor de imóveis constitui um desafio de relevância prática e económica em mercados emergentes como o angolano, onde a volatilidade de preços e a escassez de dados históricos dificultam estimativas baseadas em métodos tradicionais. Neste contexto, métodos estatísticos e de aprendizagem automática apresentam-se como ferramentas valiosas para suportar decisões de compra, venda e investimento imobiliário.

O PredicaoCasas surge como resposta a esta necessidade, implementando um modelo de Regressão Linear Múltipla que permite estimar o preço de um imóvel a partir das suas características físicas e de localização. A aplicação foi concebida com dois objectivos complementares: (i) funcionar como ferramenta prática de apoio à decisão imobiliária; e (ii) servir como plataforma educativa que demonstra, de forma transparente, o funcionamento matemático de um modelo preditivo.

A relevância do sistema reside, em particular, na sua implementação autónoma do algoritmo OLS — incluindo a inversão matricial por eliminação de Gauss-Jordan — sem dependência de bibliotecas numéricas externas, o que confere ao sistema total portabilidade e transparência algorítmica.

3. Fundamentação Teórica

3.1 Regressão Linear Múltipla

A Regressão Linear Múltipla (RLM) é um método estatístico que modela a relação entre uma variável dependente contínua y e um conjunto de p variáveis independentes (preditoras) x_1 , x_2 , ..., x_p . O modelo assume a seguinte forma funcional:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5 + \varepsilon$$

Equação (1) — Modelo de Regressão Linear Múltipla

onde $\hat{y}$ representa o preço previsto do imóvel, β_0 é o intercepto (preço base), β_1 ... β_5 são os coeficientes associados a cada preditor, e ε é o termo de erro estocástico.

3.2 Estimação por Mínimos Quadrados Ordinários (OLS)

O método OLS estima os coeficientes β minimizando a soma dos quadrados dos resíduos entre os valores observados e os valores previstos. A solução analítica é dada pela equação normal:

$$\beta = (X^T X)^{-1} \cdot X^T y$$

Equação (2) — Solução OLS (Equação Normal)

onde **X** é a matriz de design (n × 6), com a primeira coluna constituída por uns (para o intercepto), **y** é o vector de preços observados (n × 1), e $(X^T X)^{-1}$ é a inversa da matriz de Gram. A inversão matricial é realizada internamente pelo método de eliminação de Gauss-Jordan, implementado na classe `MotorRegressao.java`.

3.3 Métricas de Avaliação do Modelo

A qualidade preditiva do modelo é avaliada através de três métricas estatísticas complementares, descritas na Tabela 1:

Tabela 1 — Métricas de avaliação do modelo preditivo

Métrica	Fórmula	Interpretação
R^2 (R-quadrado)	$R^2 = 1 - SS_res / SS_tot$	Proporção da variância explicada pelo modelo (0–1)
RMSE	$RMSE = \sqrt{(\Sigma(y_i - \hat{y}_i)^2 / n)}$	Erro quadrático médio — mesma unidade do preço (Kz)
MAE	$MAE = \Sigma\lvert y_i - \hat{y}_i \rvert / n$	Erro absoluto médio — medida robusta a outliers

4. Arquitectura do Sistema

4.1 Padrão de Organização

O sistema adopta uma arquitectura em camadas (Layered Architecture), inspirada no padrão MVC (Model-View-Controller), com separação clara entre a lógica de negócio, os modelos de dados e a camada de apresentação. Esta separação garante baixo acoplamento, elevada coesão e facilidade de manutenção. A Tabela 2 descreve os componentes do sistema e as suas responsabilidades:

Tabela 2 — Componentes do sistema PredicaoCasas e respectivas responsabilidades

Ficheiro	Camada	Responsabilidade

Main.java	Camada Inicialização	Ponto de entrada; instancia e orquestra os componentes
Casa.java	Camada Modelo	Entidade que representa um imóvel com os seus atributos
ResultadoRegressao.java	Camada Modelo	Encapsula coeficientes β, R^2, RMSE e MAE do modelo
MotorRegressao.java	Camada Serviço	Implementa OLS com eliminação de Gauss-Jordan
GestaoPredicao.java	Camada Serviço	Gere dataset, treina modelo e expõe previsões
JsonUtil.java	Camada Utilitário	Serialização/deserialização do dataset em formato JSON
MainFrame.java	Camada UI	Janela principal com navegação por abas (Swing)
DashboardPanel.java	Camada UI	Visão geral com estatísticas e métricas do modelo
DatasetPanel.java	Camada UI	Tabela editável para gestão dos dados de treino
ModeloPanel.java	Camada UI	Exibe coeficientes β e métricas após o treino
GraficoPanel.java	Camada UI	Visualização gráfica: preço real vs. previsto
PredicaoPanel.java	Camada UI	Interface de sliders para previsão de novos imóveis

4.2 Fluxo de Execução

O fluxo de execução do sistema segue uma sequência bem definida de etapas:

- Inicialização: a classe Main instancia o serviço GestaoPredicao e a janela principal MainFrame;
- Carregamento de dados: o dataset de 30 imóveis sintéticos de Luanda é carregado em memória ou importado via JSON;
- Treino do modelo: ao accionar o treino, GestaoPredicao invoca MotorRegressao, que constrói a matriz X, calcula X^TX, inverte-a e obtém os coeficientes β;
- Previsão: o utilizador ajusta os sliders em PredicaoPanel e obtém uma estimativa instantânea de preço em Kwanzas;
- Visualização: os resultados são apresentados em quatro painéis (Dashboard, Dataset, Modelo, Gráfico) actualizados sincronamente.

5. Dataset e Variáveis do Modelo

O modelo foi desenvolvido e validado sobre um dataset sintético composto por 30 registos de imóveis residenciais, construídos com base em parâmetros representativos do mercado imobiliário de Luanda. O dataset inclui imóveis com características diversificadas, abrangendo desde habitações económicas a imóveis de luxo. A Tabela 3 apresenta as variáveis utilizadas no modelo:

Tabela 3 — Variáveis preditoras e variável dependente do modelo

Variável	Nome	Descrição
x_1	**Área construída**	Área total da habitação em metros quadrados (m^2)

x_2	**Número de quartos**	Quantidade de quartos disponíveis na habitação
x_3	**Número de banheiros**	Quantidade de casas de banho na habitação
x_4	**Idade do imóvel**	Anos decorridos desde a construção do imóvel
x_5	**Distância ao centro**	Distância em quilómetros ao centro de Luanda
y	**Preço (Kz)**	Variável dependente — valor de mercado em Kwanzas

O dataset pode ser expandido ou substituído pelo utilizador através da interface de gestão de dados (DatasetPanel), com suporte à importação e exportação em formato JSON, garantindo a flexibilidade do sistema para diferentes contextos geográficos e de mercado.

6. Implementação Algorítmica

6.1 Construção da Matriz de Design

Para n imóveis e p=5 preditores, a matriz de design $X \in \mathbb{R}^{n \times 6}$ é construída com a coluna de intercepto (x_0 =1) concatenada com as cinco variáveis preditoras de cada imóvel. O vector $y \in \mathbb{R}^n$ contém os preços reais correspondentes.

6.2 Inversão Matricial por Gauss-Jordan

A inversão de (X^TX) é realizada através do algoritmo de eliminação de Gauss-Jordan com pivotamento parcial, que transforma a matriz aumentada [A | I] na forma [I | A^{-1}] mediante operações elementares de linha. Esta abordagem foi escolhida por ser numericamente estável para matrizes de dimensão reduzida (6×6 neste sistema) e por não requerer bibliotecas externas.

6.3 Persistência de Dados

A serialização e deserialização do dataset é gerida pela classe JsonUtil, que implementa um parser JSON manual sem dependências externas. Os dados são guardados em formato estruturado com os campos: id, areaM2, quartos, banheiros, idadeAnos, distanciaCentroKm e precoReal (em Kz).

7. Interface Gráfica e Usabilidade

A interface gráfica foi desenvolvida com a biblioteca Swing (Java SE), organizada em cinco abas funcionais que cobrem todo o ciclo de utilização do sistema:

- Dashboard — apresenta estatísticas descritivas do dataset (preço médio, mínimo, máximo) e as métricas de desempenho do modelo (R^2, RMSE, MAE) de forma visual e intuitiva;
- Dataset — tabela interactiva para visualização, adição, edição e remoção de imóveis, com suporte a importação/exportação JSON;
- Modelo — exibe os coeficientes β estimados com respectivas interpretações práticas (ex.: valor por m² adicional);
- Gráfico — representação visual da dispersão entre preços reais e preços previstos, com indicação dos erros individuais;
- Previsão — interface de sliders para configuração das características de um novo imóvel e obtenção imediata da estimativa de preço em Kwanzas (Kz).

8. Ilustrações da Aplicação

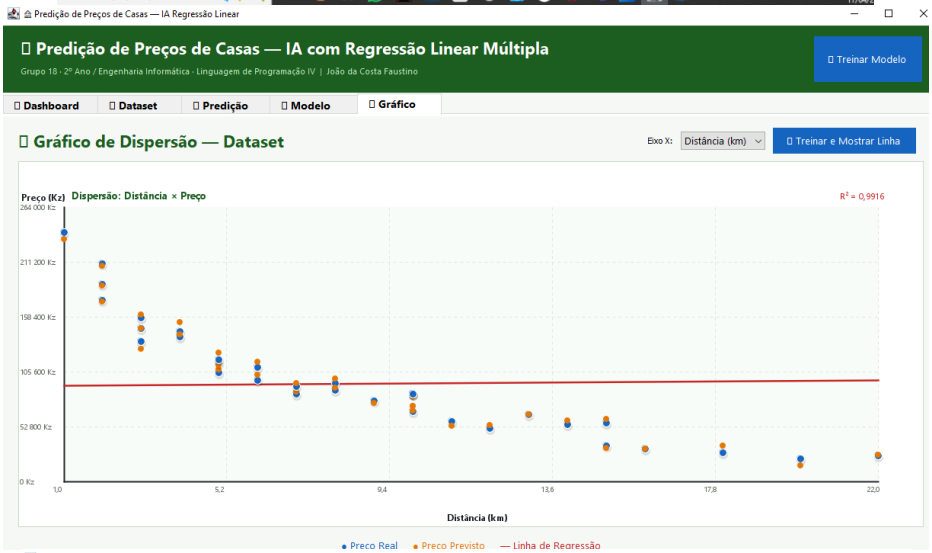

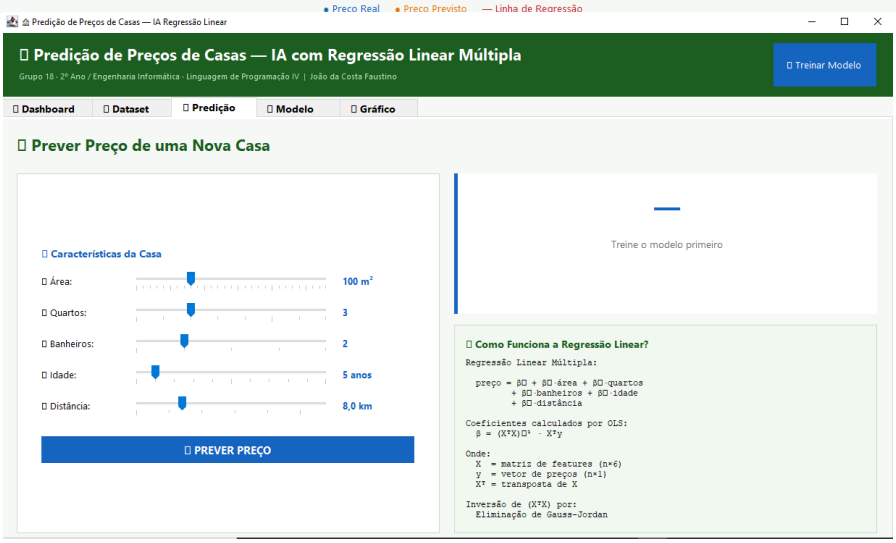

Predição de Preços de Casas — IA Regressão Linear

Predição de Preços de Casas — IA com Regressão Linear Múltipla

Grupo 18 · 2º Ano / Engenharia Informática · Linguagem de Programação IV | João da Costa Faustino

Treinar Modelo

Dashboard | Dataset | Predição | Modelo | Gráfico

Dataset de Casas

33 registros no dataset

C001	45,0	1,0	1,0	5,0	15,0	35 000 Kz	32 759 Kz	6,4%
C002	60,0	2,0	1,0	3,0	12,0	52 000 Kz	54 623 Kz	5,0%
C003	80,0	2,0	2,0	8,0	10,0	68 000 Kz	68 293 Kz	0,4%
C004	100,0	3,0	2,0	2,0	8,0	95 000 Kz	99 027 Kz	4,2%
C005	120,0	3,0	2,0	6,0	6,0	110 000 Kz	115 472 Kz	5,0%
C006	150,0	4,0	3,0	1,0	4,0	145 000 Kz	153 659 Kz	6,0%
C007	55,0	1,0	1,0	15,0	18,0	28 000 Kz	35 005 Kz	25,0%
C008	70,0	2,0	1,0	10,0	14,0	55 000 Kz	59 238 Kz	7,7%
C009	90,0	3,0	2,0	4,0	7,0	85 000 Kz	86 793 Kz	2,1%
C010	110,0	3,0	2,0	2,0	5,0	105 000 Kz	108 488 Kz	3,3%
C011	130,0	4,0	3,0	7,0	3,0	135 000 Kz	127 697 Kz	5,4%
C012	200,0	5,0	4,0	1,0	2,0	210 000 Kz	207 927 Kz	1,0%
C013	40,0	1,0	1,0	20,0	20,0	22 000 Kz	15 799 Kz	28,2%

Adicionar Casa | Remover

Predição de Preços de Casas — IA Regressão Linear

Predição de Preços de Casas — IA com Regressão Linear Múltipla

Grupo 18 · 2º Ano / Engenharia Informática · Linguagem de Programação IV | João da Costa Faustino

Treinar Modelo

Dashboard | Dataset | Predição | Modelo | Gráfico

Detalhes do Modelo Matemático

Coeficientes do Modelo (β)

β0 Intercepto
Preço base quando tudo é zero
-16 366,56 Kz

β1 Área (m²)
Cada m² adiciona este valor
+1022,80 Kz/m²

β2 Quartos
Valor por quarto adicional
+5 539,15 Kz/q

β3 Banheiros
Valor por banheiro adicional
+-1 899,77 Kz/b

β4 Idade (anos)
Depreciação anual (negativo)
-874,94 Kz/ano

β5 Distância (km)
Desconto por km do centro
255,65 Kz/km

Métricas de Avaliação

R^2: 0,991627 (Excelente)

```
INVERSÃO GAUSS-JORDAN:
  [A | I] → operações de linha → [I | A⁻¹]
  - Pivotamento parcial para estabilidade
  - Normalização da linha do pivô
  - Eliminação em todas as outras linhas

MÉTRICAS:
  R² = 1 - SS_res / SS_tot
     SS_res = Σ(yi - ŷi)²
     SS_tot = Σ(yi - ȳ)²

  RMSE = √(Σ(yi-ŷi)² / n)
  MAE  = Σ|yi-ŷi| / n
  MAPE = Σ(|yi-ŷi|/yi) / n × 100

CORRELAÇÃO DE PEARSON:
  r = Σ(xi-x̄)(yi-ȳ) / √[Σ(xi-x̄)² · Σ(yi-ȳ)²]

EQUAÇÃO DO MODELO TREINADO:

  preço = -16 366,56
    + 1 022,8019 × área
    + 5 539,1545 × quartos
    + -1 899,7736 × banheiros
    + (-874,9361) × idade
    + (255,6518) × distância

  R²   = 0,991627 (Excelente)
  RMSE = 4 887,64 Kz
  MAE  = 3 846,00 Kz
  MAPE = 5,42%
```

Treinar / Retreinar Modelo

8. Conclusão

O sistema PredicaoCasas demonstra que é possível desenvolver uma aplicação de aprendizagem automática completa, funcional e didacticamente relevante em Java puro, sem recurso a frameworks especializadas. A implementação autónoma do OLS com inversão de Gauss-Jordan confere ao sistema total transparência algorítmica, tornando-o adequado tanto para uso prático no mercado imobiliário angolano como para fins pedagógicos.

O sistema apresenta como principais pontos fortes a portabilidade (JAR executável sem dependências externas), a extensibilidade (dataset configurável e arquitectura em camadas), e a rastreabilidade matemática completa do processo de estimação. Como trabalho futuro, recomenda-se a expansão do dataset com dados reais do mercado de Luanda, a implementação de validação cruzada (k-fold cross-validation) e a adição de algoritmos alternativos como Ridge Regression para maior robustez em cenários de multicolinearidade.

9. Referências

MONTGOMERY, D. C.; PECK, E. A.; VINING, G. G. Introduction to Linear Regression Analysis. 5.ª ed. New Jersey: Wiley, 2012.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. An Introduction to Statistical Learning. 2.ª ed. New York: Springer, 2021.

GOLUB, G. H.; VAN LOAN, C. F. Matrix Computations. 4.ª ed. Baltimore: Johns Hopkins University Press, 2013.

ORACLE CORPORATION. Java Platform, Standard Edition 21 — API Specification. Disponível em: https://docs.oracle.com/en/java/javase/21/. Acedido em: Abril de 2026.

BLOCH, J. Effective Java. 3.ª ed. Boston: Addison-Wesley, 2018.